PROYECTO DE INVESTIGACIÓN DE INTELIGENCIA ARTIFICIAL E IMPACTO AMBIENTAL

Propuesta: Optimización de la Fertilización Agrícola mediante Redes de Sensores IoT y Algoritmos de Machine Learning para la Reducción de Escorrentía Tóxica.

José Carlos Ley García 21170368
Mauricio López Lara 21170377

ZURIEL DATHAN MORA FELIX

26/Febrero/2026

Introducción

La seguridad alimentaria y la integridad ecológica se manifiestan con intensidad en las regiones de agricultura. Sinaloa, conocido como el "granero de México" cuenta con un modelo de producción agrícola el cual catapultó al estado a los primeros lugares nacionales en la producción de maíz, tomate y durante más de medio siglo ha dependido de la aplicación masiva de insumos químicos sintéticos.

Este paradigma ha comenzado a mostrar fracturas irreparables en la viabilidad económica de los productores debido a la inflación de los precios de los insumos, así como el estado de los ecosistemas que sostienen la vida en la región.

La tecnología de la Agricultura de Precisión (AP) ha prometido durante años una solución a este desperdicio, proponiendo el manejo sitio-específico de los cultivos para alinear la oferta de nutrientes con la demanda fisiológica exacta de la planta. Sin embargo, la adopción de la AP en México ha sido fragmentada y lenta, obstaculizada por barreras económicas y una brecha de conocimiento técnico.[5]

No obstante, la emergencia de la cuarta revolución industrial, impulsada por el Internet de las Cosas (IoT) y la Inteligencia Artificial (IA), ofrece hoy herramientas disruptivas capaces de cerrar esta brecha. La capacidad de monitorear variables edafoclimáticas en tiempo real mediante sensores de bajo costo y procesar estos flujos de datos masivos con algoritmos de aprendizaje profundo (Deep Learning) permite, por primera vez, democratizar la eficiencia agronómica.[6]

El presente proyecto de investigación propone una solución integral que plantea un sistema cognitivo capaz de entender la dinámica compleja del suelo sinaloense. Al integrar redes de sensores distribuidos con modelos predictivos de Machine Learning, este documento articula una propuesta teórica para equilibrar la productividad agrícola con la sostenibilidad ambiental.

Objetivo General

Diseñar una propuesta teórica de un sistema basado en Inteligencia Artificial y sensores IoT que analice la composición del suelo en tiempo real para recomendar dosis precisas de fertilizantes, minimizando el impacto ambiental en los mantos acuíferos.

Objetivos Específicos

1. Investigar las tecnologías actuales de sensores IoT para la medición de nitrógeno, fósforo y potasio (NPK) en el suelo.
2. Analizar los algoritmos de IA existentes utilizados para la predicción de necesidades de nutrientes en cultivos.
3. Diseñar la arquitectura lógica y funcional de una solución que orqueste la recolección de datos mediante redes de bajo consumo, el procesamiento en la nube y la interfaz de usuario
4. Evaluar el impacto potencial de la solución propuesta en la reducción de la contaminación del agua local.

Justificación

Importancia Ambiental

La justificación ambiental de este proyecto no busca ayudar solo en la conservación; busca ayudar en las áreas de salud pública y supervivencia ecológica.

Sinaloa alberga algunos de los ecosistemas costeros más productivos y frágiles de México Sus varios cuerpos de agua actúan como receptores finales de las descargas de los distritos de riego, recibiendo anualmente miles de toneladas de químicos disueltos y reactivos. Este exceso de nutrientes altera drásticamente el agua, provocando incrementos algales nocivos (conocidos como “mareas rojas”) que consumen el oxígeno disuelto y generan zonas de hipoxia o anoxia.[1]

La consecuencia directa es: **la mortalidad masiva de especies acuáticas, la degradación de hábitats críticos para la reproducción de camarón y peces, y la afectación a especies protegidas.**[4]

Además, la infiltración de nitratos hacia las fuentes principales de agua potable para muchas comunidades rurales ha alcanzado niveles que superan las normas oficiales de salud, se especula que esto ha tenido relación con riesgos cancerígenos.[5]

Este proyecto ataca la raíz del problema: **la aplicación ineficiente de agroquímicos, proponiendo una barrera tecnológica preventiva contra la contaminación difusa.**

Alcance

El alcance de este proyecto se define para garantizar el análisis teórico y la viabilidad de la propuesta dentro de los límites académicos y técnicos.

- **Lo que este proyecto SÍ incluye:**
    - Una investigación exhaustiva y comparativa de las tecnologías de sensores para la detección de NPK, incluyendo sensores ópticos, electroquímicos y capacitivos, evaluando su física de operación y adecuación al campo.
    - La selección, justificación y descripción teórica de los algoritmos de Machine Learning (Redes Neuronales, Regresión, TabNet) idóneos para el modelado de nutrientes y la predicción de escorrentía.
    - El diseño de una arquitectura de hardware y software propuesta, que abarca desde el nodo de sensor hasta la infraestructura de nube, especificando protocolos de comunicación y flujo de datos.
    - Un análisis teórico profundo del impacto ambiental, centrado en la mitigación de la eutrofización en las lagunas costeras de Sinaloa y la protección de la biodiversidad asociada.
    - Un estudio de viabilidad económica preliminar basado en la reducción de insumos.

- **Lo que este proyecto NO incluye:**
    - La construcción física, soldadura o ensamblaje de prototipos electrónicos funcionales.
    - La realización de pruebas de campo experimentales in situ (cultivo real) ni la toma de muestras de suelo físicas para análisis de laboratorio.
    - El desarrollo completo del código fuente de software para producción comercial o el entrenamiento final de los modelos con datos primarios generados en el proyecto.
    - La manufactura de los sensores o componentes electrónicos.

- **Área de enfoque:**
    - El proyecto se contextualiza geográficamente en los valles agrícolas de los municipios de Guasave y Culiacán, Sinaloa, zonas representativas de la agricultura intensiva de riego.
    - Se centra teóricamente en los cultivos de maíz blanco (ciclo otoño-invierno) y jitomate, por ser los de mayor importancia económica y mayor demanda de fertilizantes nitrogenados en la región.

Desarrollo

1. Estado del Arte (Investigación y Análisis)

Problemas Actuales en la Fertilización Agrícola

La práctica de la fertilización en Sinaloa se encuentra atrapada en un paradigma de "mejor que sobre a que falte". Ante la incertidumbre de las condiciones del suelo y el temor a perder rendimiento, los productores tienden a **sobre fertilizar**, aplicando dosis masivas de urea, fosfato monoamónico (MAP) y cloruro de potasio al inicio del ciclo o en etapas fenológicas fijas, independientemente de la disponibilidad real de nutrientes en el suelo.[5]

Esta estrategia, aunque busca asegurar la producción, genera desequilibrios biogeoquímicos severos. La eficiencia en el uso del nitrógeno es baja; gran parte del fertilizante aplicado no es interceptado por las raíces.

El nitrógeno, en forma de nitrato (NO_3^-), es altamente móvil en el agua y se filtra rápidamente por debajo, contaminando los acuíferos, o escurre superficialmente hacia los drenajes.[6]

Este transporte de contaminantes es el motor principal de la degradación de la calidad del agua en la región, creando un ciclo vicioso donde el agricultor gasta más para contaminar más, obteniendo rendimientos marginales decrecientes.

<u>Tabla comparativa entre las técnicas de tecnologías de sensores IoT de suelo</u>

Característica	Sensores Electroquímicos (ISE)	Sensores Ópticos (Espectroscopía)	Sensores de Conductividad (EC)
Principio Físico	Potenciometría mediante membranas selectivas de iones.[7]	Reflectancia/Absorbancia de luz (UV-Vis-NIR).[13]	Conducción eléctrica en medio poroso.[8]
Detección	Iones específicos (NO_3^-, K^+, NH_4^+).	Estimación de contenido total de NPK y materia orgánica.	Salinidad total (sales disueltas), no específico.
Precisión	Alta en condiciones controladas.	Media-Alta (depende de algoritmos de calibración).	Baja para iones específicos, Alta para tendencias.
Durabilidad	Baja (Las membranas se degradan en suelo real).	Alta (Sin contacto químico directo, estado sólido).	Muy Alta (Electrodos robustos).
Costo	Alto mantenimiento.	Medio-Alto (Componentes optoelectrónicos).	Bajo.
Viabilidad IoT	Limitada para monitoreo continúo enterrado.	**Alta** (Ideal para monitoreo "on-the-go" o estacionario).	Alta (Como variable auxiliar de corrección).

Análisis de Selección:
Aunque los sensores ISE (Electrodos Selectivos de Iones) ofrecen mediciones directas similares al laboratorio, sufren de "deriva" (drift) y requieren recalibración frecuente, lo que los hace imprácticos para redes de sensores enterrados permanentemente en campos extensos.[9]

Por el contrario, la **tecnología óptica (espectroscopía de reflectancia)** combinada con sensores de conductividad eléctrica (EC) y temperatura, presenta la mayor viabilidad para el proyecto. Al iluminar el suelo con longitudes de onda específicas, se pueden correlacionar los patrones de absorción de luz con las concentraciones de nutrientes, utilizando algoritmos de IA para eliminar el ruido generado por la humedad y textura del suelo.[2]

Algoritmos de Inteligencia Artificial en Agricultura

La mera recolección de datos no es suficiente. Los modelos tradicionales de regresión lineal son incapaces de capturar las complejas interacciones no lineales del sistema suelo-planta-atmósfera.

- **Redes Neuronales Artificiales (ANN):** Investigaciones recientes [2] validan el uso de Redes Neuronales como herramientas superiores para la "calibración virtual" de sensores. Una ANN puede aprender a mapear las lecturas "ruidosas" de un sensor óptico/EC de bajo costo a valores de laboratorio precisos, compensando automáticamente variables de interferencia como la temperatura o el pH.
- **Deep Learning y TabNet:** Para la toma de decisiones agronómicas, arquitecturas avanzadas como **TabNet** han mostrado un rendimiento excepcional en datos tabulares estructurados, logrando precisiones superiores al 95% en la recomendación de fertilizantes al integrar variables históricas y de tiempo real. Estos modelos, gracias a mecanismos de atención, permiten también cierta interpretabilidad, ayudando a entender qué factores (ej. lluvia reciente o etapa del cultivo) pesaron más en la decisión.[12]
- **Predicción de Series Temporales (LSTM):** Para anticipar la demanda de nutrientes, las redes neuronales recurrentes (RNN), específicamente las de Memoria a Corto y Largo Plazo (LSTM), son ideales para modelar secuencias temporales, aprendiendo de la fenología del cultivo y el historial climático para predecir cuándo ocurrirá el pico de demanda de nitrógeno.[10]

2. Propuesta de Solución (Eco-Sense NPK)

La solución propuesta, **"Eco-Sense NPK"**, es un sistema Ciber-Físico diseñado para operar de manera autónoma en entornos rurales, cerrando el ciclo entre la detección del estado del suelo y la acción de fertilización.

Arquitectura del Sistema

La arquitectura se estructura en cuatro capas lógicas.

A. Percepción

Digitalización de las variables físicas, con **Nodos de Sensores (End-Devices)** autónomos.

Matriz de Sensores:

1. **Sonda Híbrida NPK:** Un sensor óptico de reflectancia multiespectral (Vis-NIR) integrado con electrodos de conductividad eléctrica y temperatura.
2. **Sensores Ambientales:** Medición de temperatura y humedad relativa del aire a nivel de dosel del cultivo para calcular la demanda evapotranspirativa.

B. Comunicación

Se descarta el uso de Wi-Fi por su corto alcance y se evita la dependencia exclusiva de redes celulares.

- **Protocolo: LoRaWAN** (Long Range Wide Area Network).

  LoRaWAN ofrece un alcance de 10 a 15 km en línea de vista en zonas rurales, con una excelente penetración a través de la vegetación y un consumo energético mínimo, permitiendo que las baterías duren meses o años.[3]

- **Topología:** Topología de estrella. Múltiples nodos en las parcelas transmiten datos a un **Gateway LoRaWAN** central (ubicado en una infraestructura alta existente, como un silo o bodega). Este Gateway actúa como puente, concentrando los datos y retransmitiéndolos a Internet mediante un enlace *backhaul* (4G LTE, fibra o satelital).

C. Procesamiento

- **Ingesta y Almacenamiento:** Un servidor recibe los paquetes de datos cifrados. Los datos se almacenan en una base de datos de series temporales para manejar marcas de tiempo y lecturas de sensores.
- **Fusión de Datos Externos:** El sistema consulta APIs meteorológicas para obtener pronósticos de precipitación. **Es crítico**: el sistema está programado para vetar recomendaciones de fertilización si la probabilidad de lluvia intensa supera un umbral en las próximas 24-48 horas, previniendo así la lixiviación por lavado.

- **Motor de IA (Modelado y Decisión):**

1. **Sub-modelo de Calibración (ANN):** Procesa las señales crudas (voltajes ópticos/EC) y las corrige con temperatura/humedad para estimar el NPK real.[2]
2. **Sub-modelo de Recomendación (Random Forest / TabNet):** Toma el estado actual de nutrientes y el pronóstico climático para calcular la dosis óptima (kg/ha) de fertilizante.

D. Aplicación

La interfaz final para el agricultor se presenta como una aplicación web progresiva (PWA) o dashboard móvil.

- **Visualización:** Mapas de calor de la parcela indicando niveles de nutrientes (Semáforo: Verde/Óptimo, Amarillo/Bajo, Rojo/Crítico).
- **Accionabilidad:** Alertas push claras: *"Déficit de Nitrógeno detectado en Sector Norte. Recomendación: Aplicar 25 kg/ha de Urea. Ventana de aplicación segura: Próximas 72 horas (Sin lluvia pronosticada)."*

Innovación de la Propuesta

La innovación central de **Eco-Sense NPK** no es tecnológica, sino conceptual. A diferencia de los sistemas comerciales que priorizan la maximización ciega del rendimiento, esta propuesta introduce la **restricción ambiental** en el algoritmo de decisión.

La integración del pronóstico meteorológico como mecanismo de bloqueo para la fertilización es una característica distintiva que mitiga directamente el riesgo de contaminación acuífera.

El uso de IA para elevar la precisión de sensores de bajo costo hace que la agricultura de precisión sea económicamente viable para productores medianos, rompiendo la barrera de entrada de los equipos de laboratorio costosos.

3. Impacto Ambiental Esperado

La implementación masiva de este sistema tendría un efecto restaurador profundo en los ecosistemas de Sinaloa.

Al sincronizar la oferta de fertilizante con la demanda fisiológica real de la planta y evitar las aplicaciones "por calendario" o previas a lluvias, se estima teóricamente una reducción del **20% al 30%** en el uso total de fertilizantes nitrogenados.[11] Esto se traduce en una disminución directa de miles de toneladas de nitratos que anualmente ingresan a los drenes agrícolas. Esto permitiría la recuperación de los niveles de oxígeno disuelto, mitigando las zonas muertas y permitiendo la regeneración de la flora y fauna bentónica.

La reducción protege los pozos de agua potable de la contaminación por nitratos, reduciendo la incidencia de problemas de salud en comunidades agrícolas. Económicamente, el ahorro en la compra de fertilizantes mejora la rentabilidad del productor.

Agenda

A continuación se presenta el cronograma estimado para el desarrollo de la investigación y diseño teórico (simulado para un periodo académico de 8 semanas):

Fase	Actividad	Tiempo Estimado	Descripción Detallada
Fase 1	Investigación bibliográfica y selección de hardware	*Semanas 1-2*	Revisión sistemática de literatura sobre sensores NPK (ópticos vs. ISE) y selección final de componentes (ESP32, módulos LoRa SX1276). Definición de requerimientos técnicos.
Fase 2	Diseño de arquitectura y modelo de datos	*Semanas 3-4*	Diagramación detallada de la red LoRaWAN (topología, gateways). Diseño del esquema de base de datos y definición de variables de entrada/salida para las Redes Neuronales.
Fase 3	Simulación de escenarios y entrenamiento de IA	*Semanas 5-6*	Recopilación de datasets públicos (ej. datos climáticos históricos de Sinaloa y datos de suelo de INIFAP). Entrenamiento preliminar de modelos de IA (Python/TensorFlow) para validar la lógica de recomendación.
Fase 4	Análisis de resultados y ajuste de la propuesta	*Semana 7*	Evaluación teórica del desempeño de los modelos. Proyección de ahorro de fertilizante y reducción de contaminantes. Ajuste de parámetros del sistema.
Fase 5	Elaboración del informe final y presentación	*Semana 8*	Redacción y estructuración del documento final. Preparación de material visual y defensa de la propuesta ante el comité académico.

Conclusiones

Se pudo Confirmar que unir la IA con un sensor conectado a internet que vendría siendo el LoT es la mejor forma para poder asegurar que la agricultura en Sinaloa tenga un excelente futuro ya que actualmente, se abusa del uso del fertilizante y sin darse cuenta eso pasa factura demasiado rápido, además de mencionar que daña seriamente el medio ambiente, contaminándolo en diferentes áreas tales como el Mar y la salud de todo lo que lo rodea. Con el Eco-Sense NPK se demostró que es posible tener tecnología de calidad sin que sea demasiado costosa o lo mejor de los casos que no sea difícil de usar. Gracias a los programas inteligentes y sensores accesibles, podemos darle a la tierra exactamente lo que se necesita en el momento. Mirándolo de otro modo esto ayuda a los agricultores en el ámbito económico ahorrando dinero además de que protegen a la naturaleza. La tecnología debe servir para producir alimentos de manera responsable, cuidando el suelo y el agua sobre todo para poder continuar cultivando por muchos años más sin destruir el entorno que tenemos que proteger.

En conclusión, la Inteligencia Artificial en la agricultura puede llegar a ser un instrumento de gestión cognitiva que permite armonizar la actividad humana con los ciclos naturales. La adopción de estas tecnologías es un paso necesario para una agricultura climáticamente inteligente, capaz de alimentar a la población sin sacrificar los ecosistemas que hacen posible la vida.

Enlace a GitHub

https://github.com/LeyCarlos-21170368/Topicos-de-IA.git

Referencias Bibliográficas

1. En Sinaloa, la innovación agrícola no alcanza a todo el campo por igual - Revista Espejo, fecha de acceso: febrero 16, 2026, https://revistaespejo.com/2025/06/24/en-sinaloa-la-innovacion-agricola-no-alcanza-a-todo-el-campo-por-igual/

2. A REVIEW ON DESIGN AND DEVELOPMENT OF NPK SENSOR, fecha de acceso: febrero 16, 2026, https://jseepublisher.com/wp-content/uploads/20-JSEE3223.pdf

3. (PDF) COMPARATIVE ANALYSIS OF ECONOMIC IMPACT AND ..., fecha de acceso: febrero 16, 2026, https://www.researchgate.net/publication/384015672_COMPARATIVE_ANALYSIS_OF_ECONOMIC_IMPACT_AND_PROFITABILITY_OF_A_COMPUTER_AUTONOMY_SYSTEM_AP_VS_TRADITIONAL_AGRICULTURE_IN_POTATO_PRODUCTION_IN_THE_VALLEY_OF_GUASAVE_SINALOA

4. Os pas - Conanp, fecha de acceso: febrero 16, 2026, https://www.conanp.gob.mx/programademanejo/PMPlayaHuizacheCaimanero.pdf

5. Los fertilizantes agrícolas contaminan miles de pozos en el Valle de Salinas | 90.3 KAZU, fecha de acceso: febrero 16, 2026, https://www.kazu.org/kazu-news/2026-02-04/los-fertilizantes-agricolas-contaminan-miles-de-pozos-en-el-valle-de-salinas

6. "Suben precios de insumos agrícolas en Sinaloa" - Periódico Noroeste, fecha de acceso: febrero 16, 2026, https://www.noroeste.com.mx/hubnegocios/suben-precios-de-insumos-agricolas-en-sinaloa-GBNO446426

7. Sensores de Suelo para Agricultura de Precisión, fecha de acceso: febrero 16, 2026, https://agriculturadeprecision.org.pe/sensores-de-suelo-para-agricultura-de-precision/

8. Electrochemical Sensors for Soil Nutrient Detection: Opportunity and Challenge., fecha de acceso: febrero 16, 2026, https://opendl.ifip-tc6.org/db/conf/ifip12/ccta2007-2/LinWZZC07.pdf

9. An Optical Soil Sensor for NPK Nutrient Detection in Smart Cities - Wei Fan, fecha de acceso: febrero 16, 2026, https://fanwei100.github.io/files/An%20Optical%20Soil%20Sensor%20for%20NPK%20Nutrient%20Detection%20in%20Smart%20Cities.pdf

10. Agriculture Technology | Precision Ag - John Deere, fecha de acceso: febrero 16, 2026, https://www.deere.com/en/technology-products/precision-ag-technology/

11. Vaquita Marina - A Victim of Dark Markets - ArcGIS StoryMaps, fecha de acceso: febrero 16, 2026, https://storymaps.arcgis.com/stories/291013d45a9d4857aaa0fa8239202480

12. Correlación del comportamiento de una arquitectura de red LoRaWAN con modelos de propagación en un entorno con vegetación - SEDICI, fecha de acceso: febrero 16, 2026, https://sedici.unlp.edu.ar/handle/10915/175161

13. Interpretable deep learning models for independent fertilizer and crop recommendation - PMC, fecha de acceso: febrero 16, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12644580/